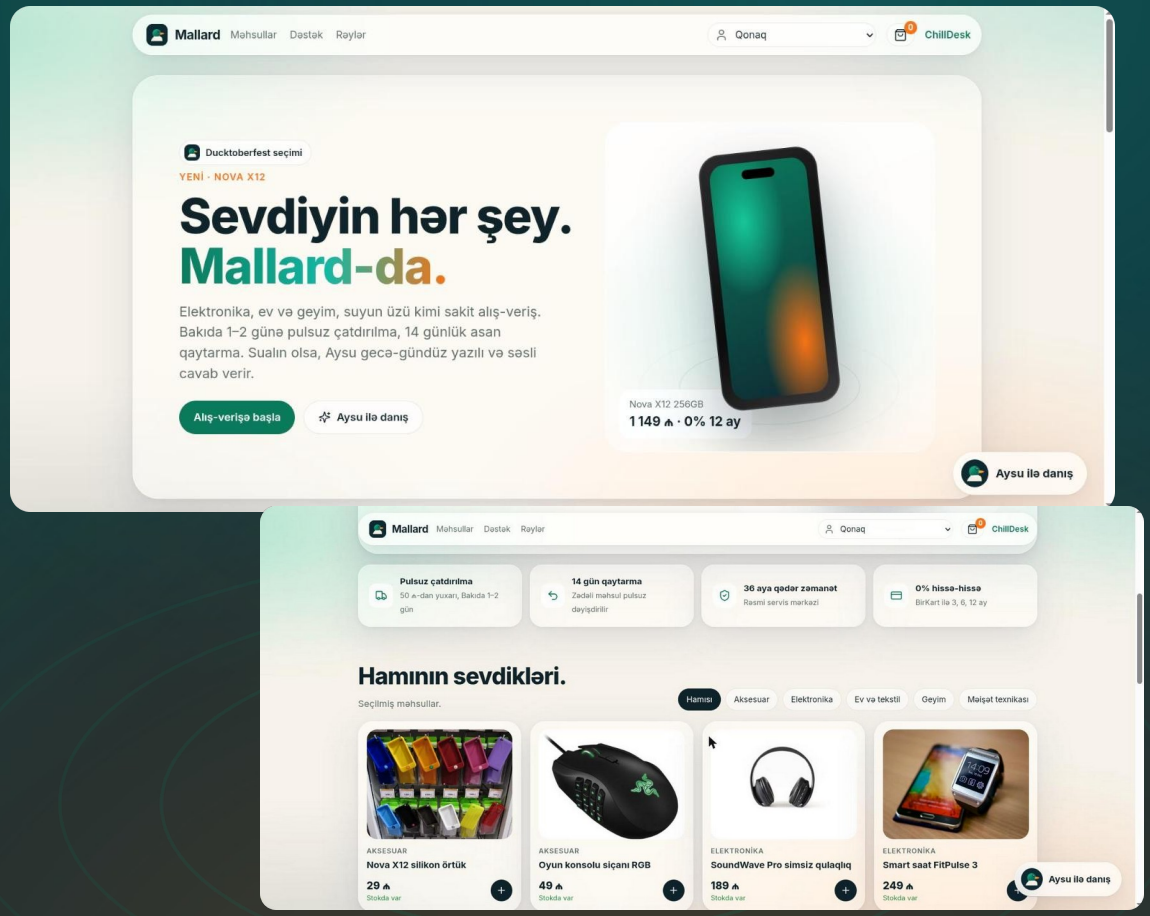
ChillDesk

Açıq çəkili Gemma 4 ilə onlayn mağazalar üçün AI dəstək agenti

Best Use of Gemma 4 | **Best Open-Source AI Project**



team-Chill · Ducktoberfest Baku 2026 · Hacktoberfest Hack Day

Müştəri dəstəyi yavaş, baha və dağınıqdır

Suallar 24/7 gəlir

“Sifarişim haradadır?”, “pulum nə vaxt qayıdır?” — eyni suallar gecə-gündüz təkrarlanır, cavab növbədə gözləyir.

Şəkil və zəng əl ilə

Zədəli məhsulun şəkli, telefon zəngi, qəbz — operator hər birinə baxıb sistemdə əl ilə qərar verir.

Əl ilə hesabat

Xülasə, kateqoriya, bilet, müştəriyə follow-up email — hər söhbətdən sonra dəqiqələr itir.

Kiçik mağazanın 24/7 dəstək komandası saxlamağa imkanı yoxdur.

Tanış olun: Aysu

Chat + real hərəkət

Gemma 4 function calling: sifarişi tapır, izləyir, qaytarma və bilet açır

Şəkli görür

Zədəli məhsulun şəkli → Gemma 4 vision → qərar

Səsli zəng, 3D Aysu

Lipsync, tona görə emosiya, Azərbaycan dilində

Avtomatlaşdırma

Xülasə, prioritet, avto-bilet, follow-up email



Aysu · Mallard dəstək agenti

Şəkil göndər, həll al



Müştərinin göndərdiyi şəkil

≈13 saniyə · 4 tool çağırışı · 0 operator



1. **Gemma 4 şəkli görür**

   “sol qulaqcıqda çat” → photo_assessment

2. **list_orders → get_order**

   Leyla-nın ML-1042 sifarişini Neon-dan tapır

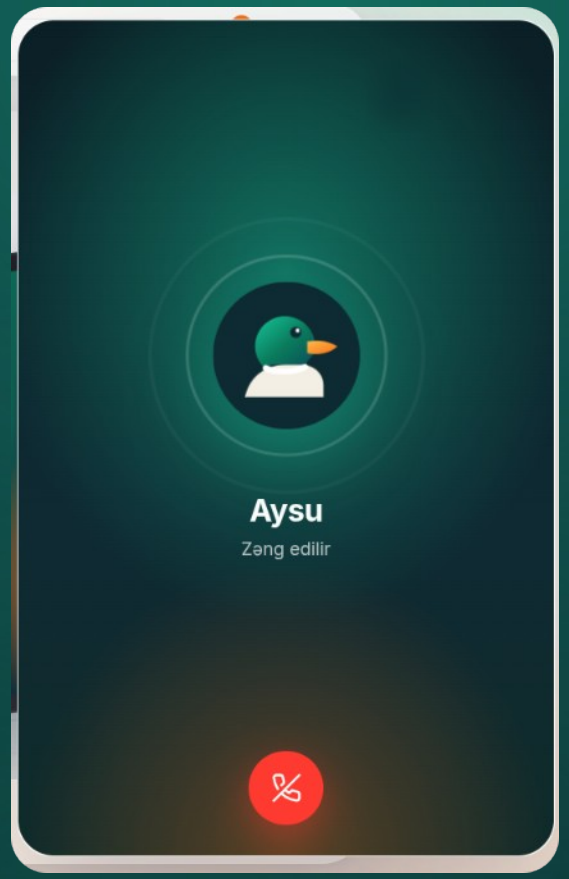
3. **create_return**

   Qayda mühərriki: 14 gün + zədə = pulsuz dəyişmə

4. **Cavab + müraciət RT-...**

   Kuryer köhnəni götürür, yenisini gətirir

Zəng kimi: səsli Aysu





Beyin Gemma 4-dür

ElevenLabs yalnız STT/TTS; cavabı bizim Custom LLM endpoint verir

Hərf səviyyəsində lipsync

Hər səs hissəsinin hərf zamanlaması + səsin real gücü

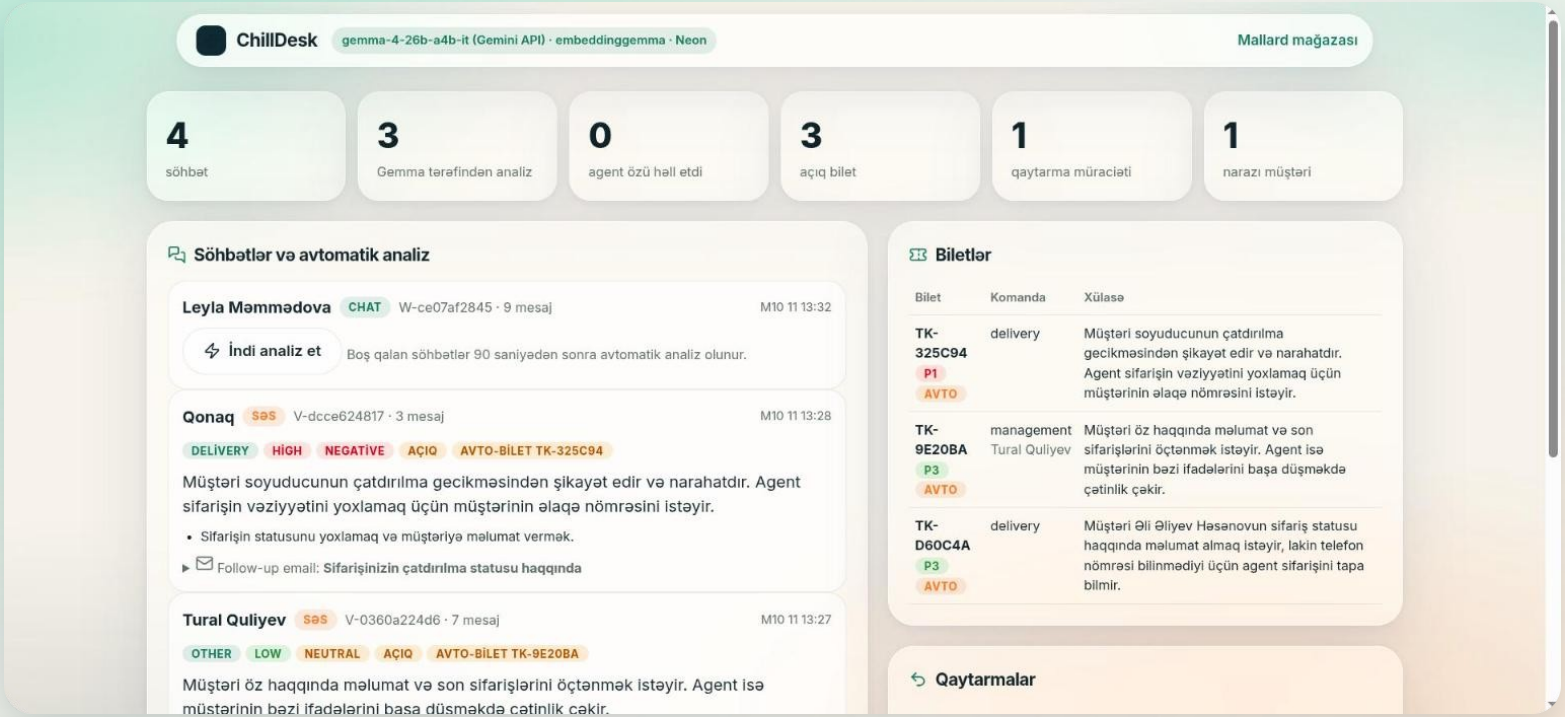
Tona görə emosiya

[empathetically] səsi də, üzü də dəyişir

Real zəng hissi

425 Hz “duut... duut”, qoşulanda Aysu görünür

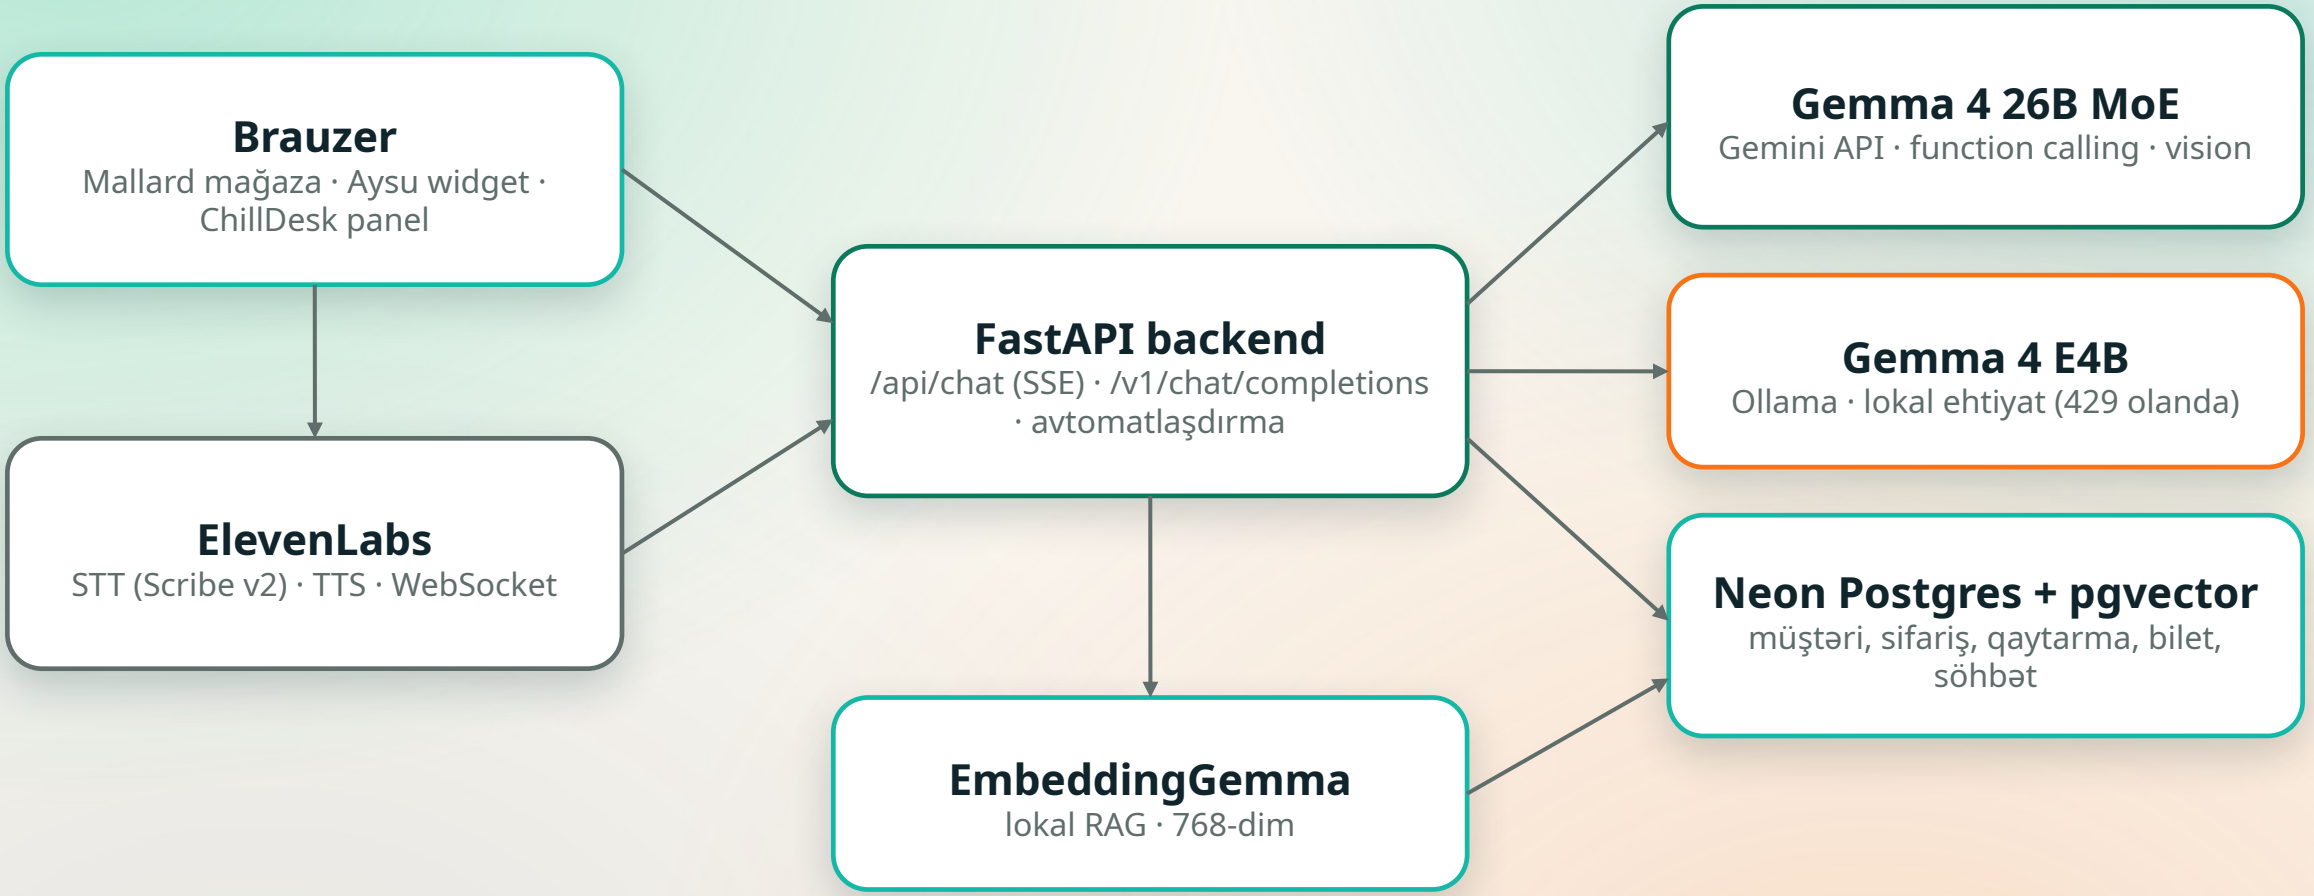
Söhbət bitir, iş özü görülür



Gemma 4 → JSON

- Xülasə
- Kateqoriya
- Təcililik
- Emosiya
- Həll olundu?
- İnsan lazımdır?
- Avto-bilet
- Follow-up email
- KB boşluğu

Arxitektura



Öz modelimizi öyrətdik: Unsloth QLoRA

229
etiketli Azərbaycanca söhbət

1B
parametr — Gemma 3 1B (4-bit)

8 GB
noutbuk GPU (RTX 4070)

~ dəq
train müddəti

1 · Data

Etiketləri əvvəlcə seçirik (7 kateqoriya × 3 təcililik × 3 emosiya, 12 məhsul, 6 müştəri üslubu), Gemma 4 26B onlara uyğun söhbət yazır. Ground truth dəqiqdir.

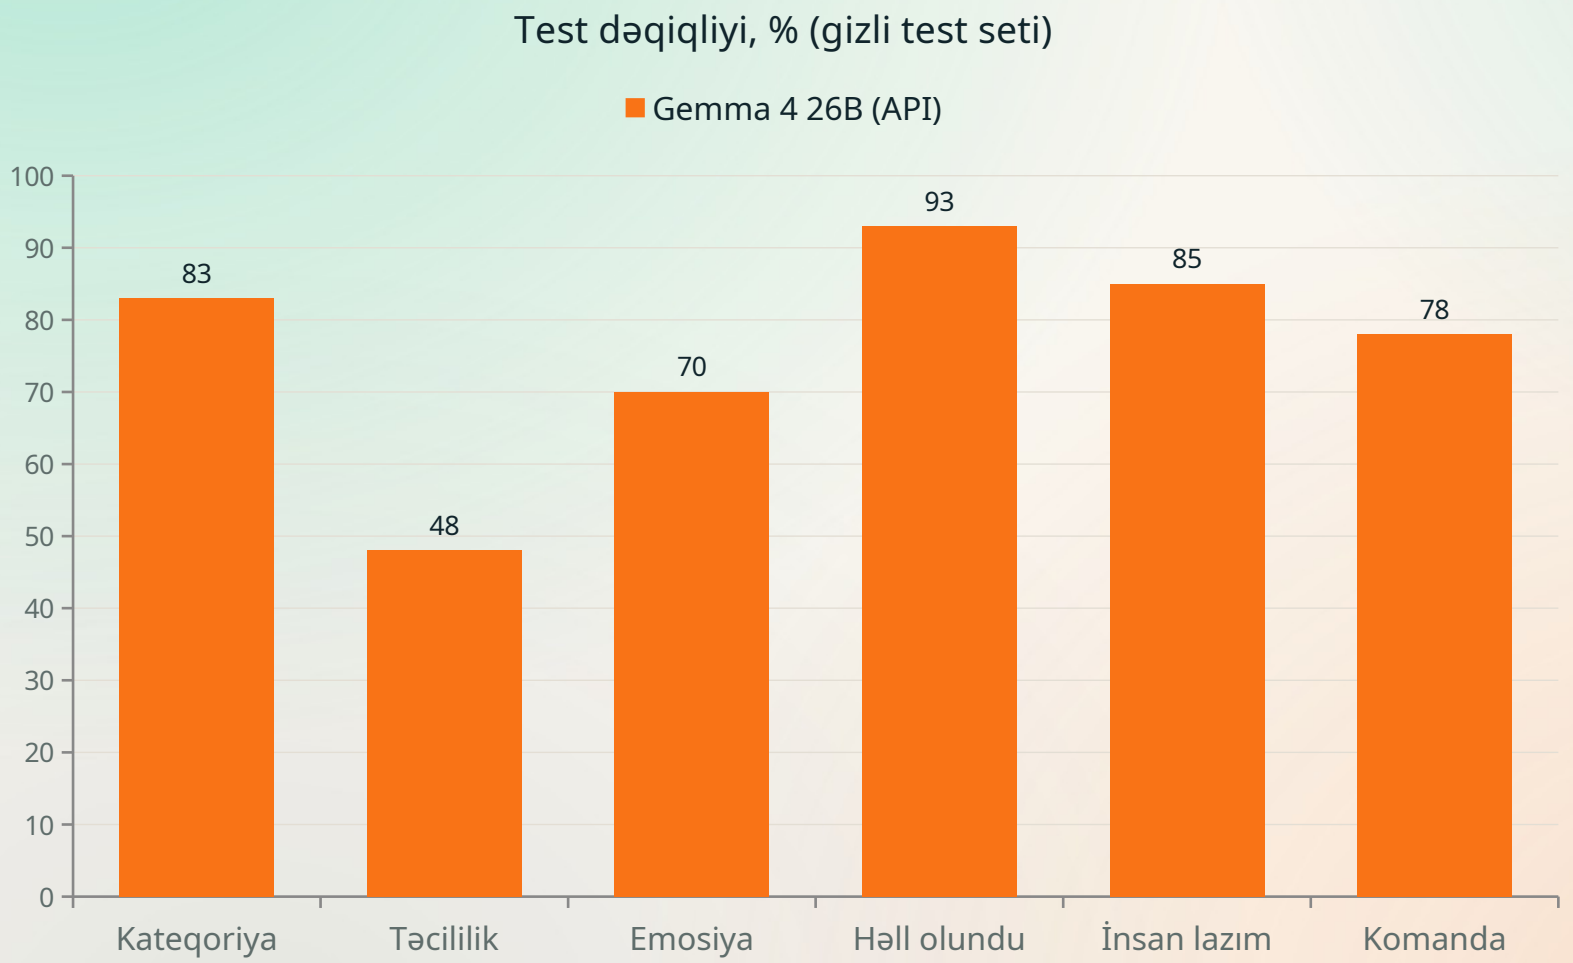
2 · Train

Unsloth QLoRA, rank 16, yalnız JSON cavab üzərində loss. Kiçik model bizim etiket qaydalarımızı öyrənir.

3 · Eval

40 gizli test söhbəti: base 1B vs fine-tuned 1B vs Gemma 4 26B. Hər sahə ayrıca ölçülür.

Nəticə: kiçik model, böyük fərq



...%

fine-tuned 1B orta dəqiqlik

...%

eyni model, fine-tune-suz

76%

Gemma 4 26B, zero-shot

Hamısı açıq

Gemma 4 26B / E4B

Agent, vision, analiz

Apache 2.0

EmbeddingGemma

Lokal RAG embedding

Gemma Terms

Gemma 3 1B + LoRA

Fine-tuned analitik

Gemma Terms

Unsloth · Ollama

Train və lokal inferens

Apache 2.0 · MIT

Neon · pgvector

Postgres + vektor axtarışı

Apache 2.0 · PostgreSQL

ChillDesk kodu

github.com/Ducktoberfest/team-Chill

MIT

Təşəkkürlər!

İndi Aysuya zəng edək.

github.com/Ducktoberfest/team-Chill

